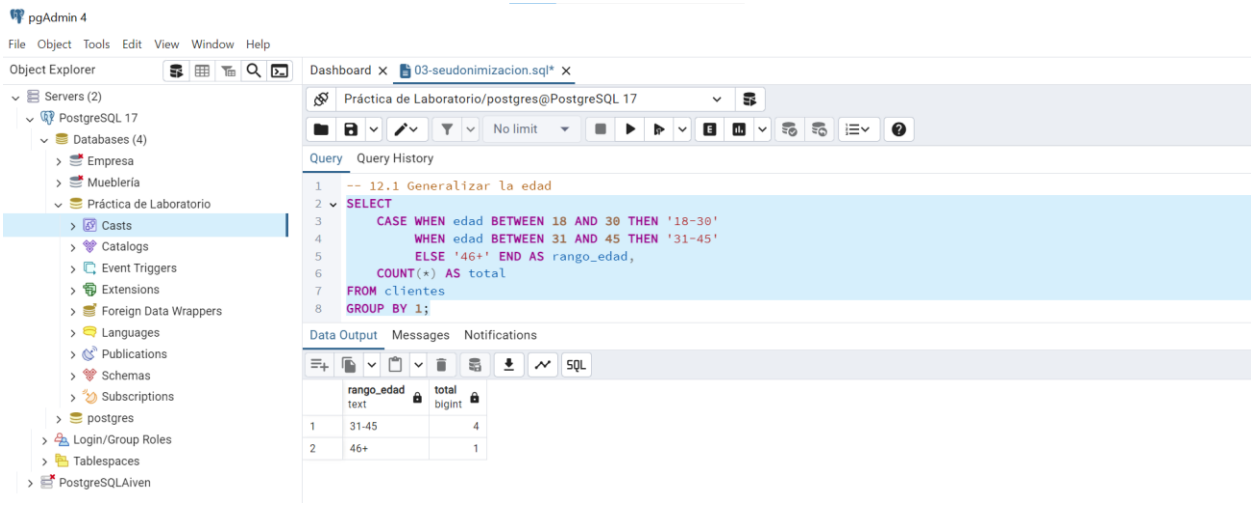
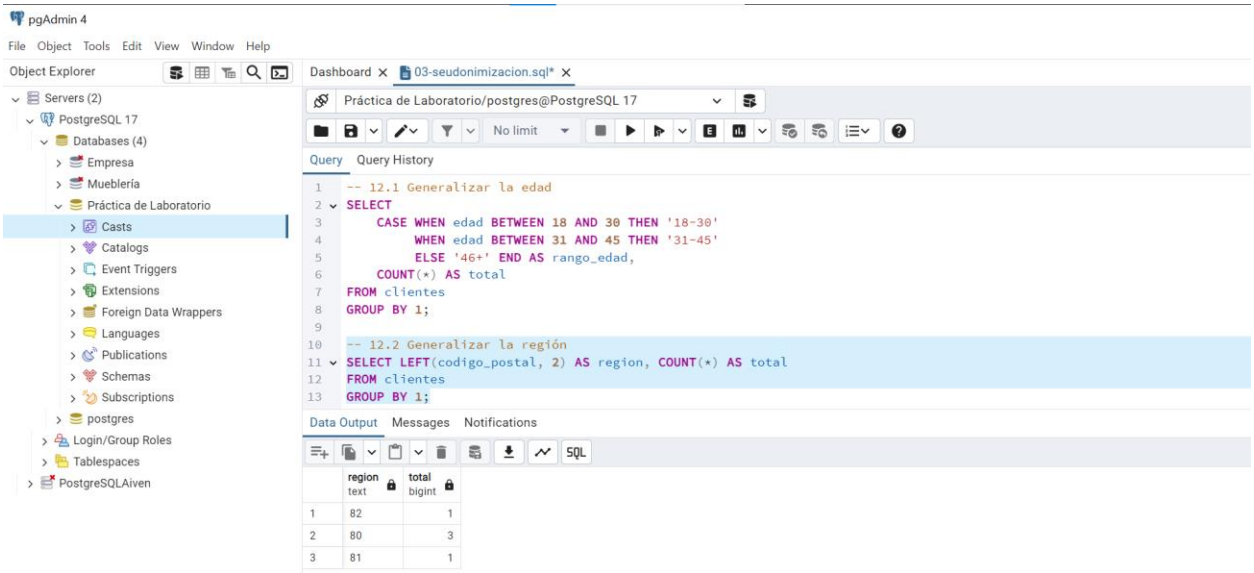
Actividades 5 y 6 - Anonimización y Análisis del riesgo de reidentificación

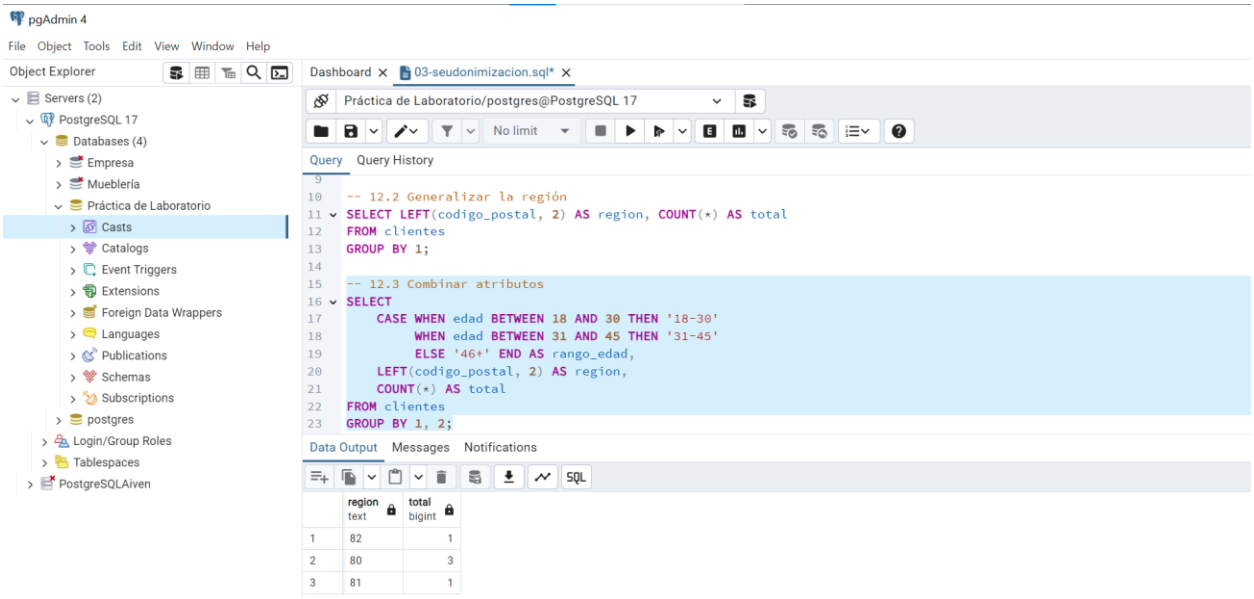
Estudiante: Jesús Jared Recio Ozúa

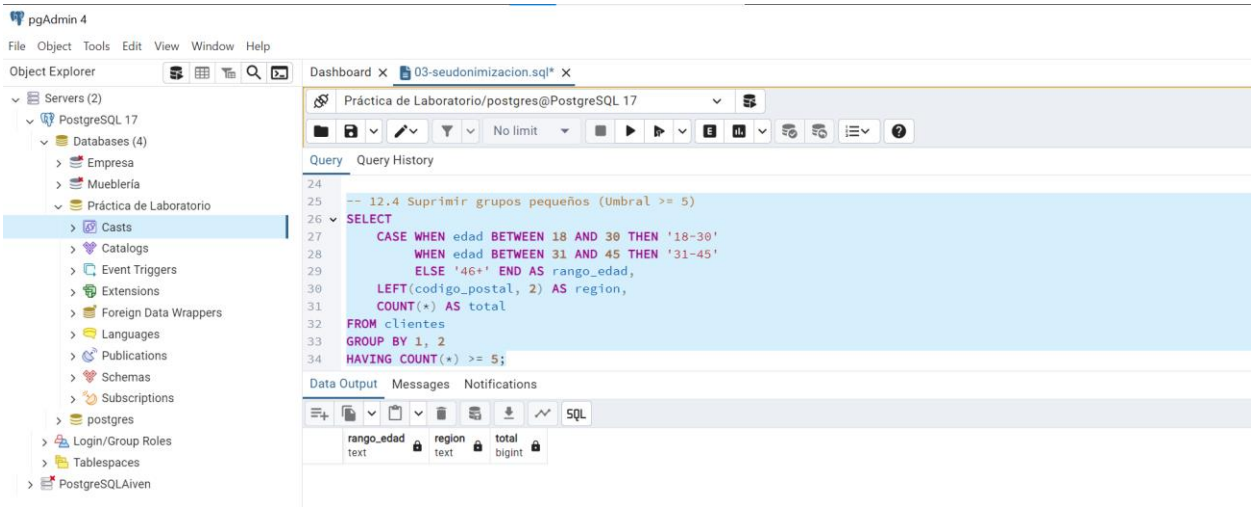
Fecha: 22 de octubre de 2026

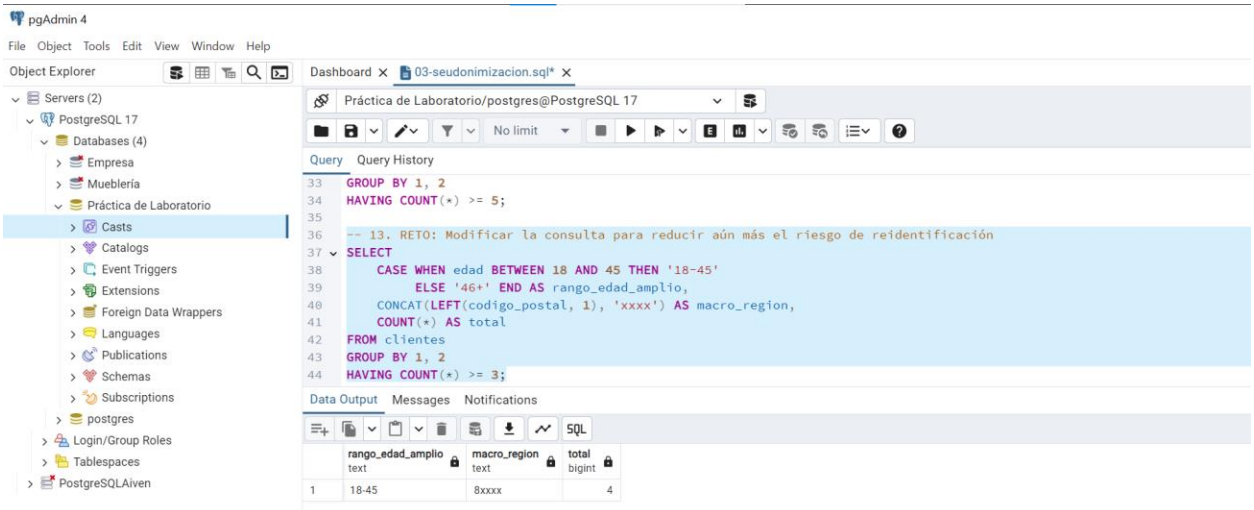
Capturas de pantalla






pgAdmin 4
File Object Tools Edit View Window Help
Object Explorer
Servers (2)
PostgreSQL 17
Databases (4)
Empresa
Mueblería
Práctica de Laboratorio
Casts
Catalogs
Event Triggers
Extensions
Foreign Data Wrappers
Languages
Publications
Schemas
Subscriptions
postgres
Login/Group Roles
Tablespaces
PostgreSQLAiven
Dashboard
03-seudonimizacion.sql*
Práctica de Laboratorio/postgres@PostgreSQL 17
No limit
Query
Query History
-- 12.2 Generalizar la región
SELECT LEFT(codigo_postal, 2) AS region, COUNT(*) AS total
FROM clientes
GROUP BY 1;
-- 12.3 Combinar atributos
SELECT
CASE WHEN edad BETWEEN 18 AND 30 THEN '18-30'
WHEN edad BETWEEN 31 AND 45 THEN '31-45'
ELSE '46+' END AS rango_edad,
LEFT(codigo_postal, 2) AS region,
COUNT(*) AS total
FROM clientes
GROUP BY 1, 2;
Data Output
Messages
Notifications
SQL
region text
total bigint
1 82 1
2 80 3
3 81 1


pgAdmin 4
File Object Tools Edit View Window Help
Object Explorer
Servers (2)
PostgreSQL 17
Databases (4)
Empresa
Mueblería
Práctica de Laboratorio
Casts
Catalogs
Event Triggers
Extensions
Foreign Data Wrappers
Languages
Publications
Schemas
Subscriptions
postgres
Login/Group Roles
Tablespaces
PostgreSQLAiven
Dashboard
03-seudonimizacion.sql*
Práctica de Laboratorio/postgres@PostgreSQL 17
No limit
Query
Query History
-- 12.4 Suprimir grupos pequeños (Umbral >= 5)
SELECT
CASE WHEN edad BETWEEN 18 AND 30 THEN '18-30'
WHEN edad BETWEEN 31 AND 45 THEN '31-45'
ELSE '46+' END AS rango_edad,
LEFT(codigo_postal, 2) AS region,
COUNT(*) AS total
FROM clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 5;
Data Output
Messages
Notifications
SQL
rango_edad text
region text
total bigint


pgAdmin 4
File Object Tools Edit View Window Help
Object Explorer
Servers (2)
PostgreSQL 17
Databases (4)
Empresa
Mueblería
Práctica de Laboratorio
Casts
Catalogs
Event Triggers
Extensions
Foreign Data Wrappers
Languages
Publications
Schemas
Subscriptions
postgres
Login/Group Roles
Tablespaces
PostgreSQLAiven
Dashboard
03-seudonimizacion.sql*
Práctica de Laboratorio/postgres@PostgreSQL 17
No limit
Query
Query History
GROUP BY 1, 2
HAVING COUNT(*) >= 5;
-- 13. RETO: Modificar la consulta para reducir aún más el riesgo de reidentificación
SELECT
CASE WHEN edad BETWEEN 18 AND 45 THEN '18-45'
ELSE '46+' END AS rango_edad_amplio,
CONCAT(LEFT(codigo_postal, 1), 'xxxx') AS macro_region,
COUNT(*) AS total
FROM clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 3;
Data Output
Messages
Notifications
SQL
rango_edad_amplio text
macro_region text
total bigint
1 18-45 8xxxx 4

Preguntas de la Actividad 6

1. ¿Qué identificadores directos fueron eliminados?

Fueron eliminados por completo id, nombre, correo, teléfono y rfc.

2. ¿Qué cuasi-identificadores permanecen?

Permanecen de forma transformada la edad (agrupada en rango_edad) y el codigo_postal (truncado a los primeros 2 dígitos como region).

3. ¿Qué combinaciones de atributos podrían reducir el anonimato?

La combinación de rango_edad + region (y si se añadieran otros cuasi-identificadores como ciudad o fecha_alta), ya que segmenta los datos en grupos más específicos donde es fácil aislar a individuos únicos.

4. ¿Qué sucede cuando un grupo contiene pocos registros?

El riesgo de reidentificación aumenta drásticamente; cuando un grupo tiene un conteo de 1 o 2 registros (como ocurrió en la consulta 12.3 con las regiones 81 y 82), basta con conocer la edad aproximada y ciudad de una persona para identificarla dentro de la estadística.

5. ¿Qué atributos deberían generalizarse?

Deberían generalizarse aún más la edad (en rangos más amplios) y el codigo_postal (reduciendo la precisión geográfica al primer dígito o macro-zona).

6. ¿Qué información debería suprimirse?

Además de suprimir todos los identificadores directos, deben suprimirse las filas o grupos estadísticos que no alcancen el umbral mínimo de registros establecido mediante la cláusula HAVING COUNT(*) >= k.

7. ¿Es correcto afirmar que el conjunto de datos es "100% anónimo"? ¿Por qué?

No. Ninguna técnica aislada garantiza un anonimato del 100% de manera absoluta, ya que el riesgo de reidentificación siempre depende del contexto, del tamaño de la muestra, de las variables disponibles y de las fuentes de información externas con las que un tercero pueda cruzar los datos.

Documentación del Reto

- **Cambio realizado:** Se modificó la consulta unificando los rangos de edad de 18 a 45 años en una sola categoría (18-45), se generalizó el código postal a solo su primer dígito (CONCAT(LEFT(codigo_postal, 1), 'xxxx')) y se estableció un umbral HAVING COUNT(*) >= 3.
- **Motivo:** Al truncar el código postal a 2 dígitos (80, 81, 82), los clientes de Los Mochis (81200) y Mazatlán (82000) quedaban en grupos de 1 solo registro, y al aplicar HAVING COUNT(*) >= 5 sobre una muestra total de 5 clientes se suprimía toda la tabla.
- **Resultado obtenido:** Se generó un grupo agregado seguro (rango_edad_amplio = '18-45', macro_region = '8xxxx', total = 4) y se suprimió automáticamente el caso aislado de 46+ (1 solo registro).
- **Riesgo que se pretende reducir:** El riesgo de singularización (*singling out*) y reidentificación de clientes que habitan en zonas postales con baja densidad de registros dentro de la muestra.